

Project 3 Τεχνολογίες Ανάλυσης Μεγάλων Δεδομένων

Κωνσταντίνα Μαρίνα Μπλέτσα, AEM: 243

Στην παρούσα εργασία υλοποιήθηκαν δύο εφαρμογές σε Apache Spark, χρησιμοποιώντας Scala σε Virtual Machine μέσω της εφαρμογής IntelliJ.

Υποεργασία 1

Στην πρώτη άσκηση χρησιμοποιήθηκε το RDD API με στόχο τον υπολογισμό του μέσου μήκους λέξεων ανάλογα με το αρχικό γράμμα ο κώδικας σε Scala βρίσκεται στο αρχείο subtask1. Αρχικά διαβάστηκε το αρχείο SherlockHolmes.txt και έγινε μετατροπή των κεφαλαίων σε πεζά και αφαίρεση των σημείων στίξης. Οι λέξεις διαχωρίστηκαν με flatMap και φιλτραρίστηκαν ώστε να παραμείνουν μόνο όσες ξεκινούν από γράμμα (`filter(word => word.charAt(0).isLetter)`). Στη συνέχεια δημιουργήθηκαν ζεύγη (γράμμα, (μήκος, 1)) και έγινε συνάθροιση μέσω reduceByKey, τέλος υπολογίστηκε και ο μέσος όρος διαιρώντας το συνολικό μήκος με τον συνολικό αριθμό λέξεων για κάθε γράμμα. Τα αποτελέσματα ταξινομήθηκαν σε φθίνουσα σειρά ως προς τον μέσο όρο και είναι τα παρακάτω:

c 7.09
e 7.03
q 6.96
p 6.92
r 6.75
d 6.25
v 5.81
g 5.80
z 5.63
u 5.57
j 5.49
s 5.39
k 5.26
l 5.19
f 5.13
m 5.07
n 4.73
b 4.48
w 4.24
h 3.77
a 3.71
y 3.67
t 3.59
i 3.42
o 2.99
x 2.65

Υποεργασία 2

Στη δεύτερη υποεργασία χρησιμοποιήθηκαν Spark DataFrames για την ανάλυση tweets. Το αρχείο CSV φορτώθηκε με αυτόματη αναγνώριση τύπων (`inferSchema = true`) και ακολούθησε καθαρισμός του κειμένου με `regexp_replace` και `lower` για δημιουργία της στήλης `clean_text`. Για το πρώτο ερώτημα, το κείμενο διαχωρίστηκε σε λέξεις με `explode(split(...))` και υπολογίστηκαν οι συχνότητες λέξεων ανά κατηγορία (`positive`, `negative`, `neutral`). Χρησιμοποιώντας (`row_number().over(...)`) βρέθηκαν οι 5 συχνότερες λέξεις για κάθε κατηγορία. Για το δεύτερο ερώτημα, έγινε φιλτράρισμα των tweets με `negativereason_confidence > 0.5` και ομαδοποίηση ανά αεροπορική εταιρεία και λόγο παραπόνου, από όπου με την ίδια τεχνική αναδείχθηκε η συχνότερη αιτία για κάθε εταιρεία. Τα αποτελέσματα από την άσκηση είναι τα παρακάτω:

=== Top 5 words per sentiment ===

+-----+-----+-----+-----+				
airline_sentiment	word	count	rank	
+-----+-----+-----+-----+				
negative	to	5656	1	
negative	the	3756	2	
negative	a	2933	3	
negative	and	2621	4	
negative	on	2560	5	
neutral	to	1564	1	
neutral	the	891	2	
neutral	a	743	3	
neutral	etlue	670	4	
neutral	you	665	5	
positive	to	869	1	
positive	the	866	2	
positive	you	722	3	
positive	for	620	4	
positive	etlue	550	5	
+-----+-----+-----+-----+				

=== Main complaint reason per airline (confidence > 0.5) ===

+-----+-----+-----+-----+				
airline	negativereason	count rank		
+-----+-----+-----+-----+				
American	Customer Service Issue	654	1	
Delta	Late Flight	228	1	
Southwest	Customer Service Issue	323	1	
US Airways	Customer Service Issue	698	1	
United	Customer Service Issue	545	1	
Virgin America	Customer Service Issue	51	1	
+-----+-----+-----+-----+				